



Evolution phonétique des langues et réseaux de neurones

Clémentine Fourier



Inria (ALMA_{na}CH)

RECITAL 2020



Etude de l'évolution phonétique des langues

- Hypothèse Néogrammarienne : **Régularité des changements phonétiques**¹

1. Hermann Osthoff et Karl Brugmann, *Morphologische Untersuchungen auf dem Gebiete der indogermanischen Sprachen*, volume 3 (S. Hirzel, 1880).

Etude de l'évolution phonétique des langues

- Hypothèse Néogrammarienne : **Régularité des changements phonétiques**¹

Si, à un moment donné dans le temps, un phone d'une langue évolue en un autre phone dans un mot, alors toutes les occurrences de ce phone dans ce contexte évoluent de la même façon.

Ex : [ka] Latin Vulgaire > ... > [ʃa] Français

- *cattus* *[kat.tʊs] > *chat* [ʃa]
- *vacca* *[vak.ka] > *vache* [vaʃ]

1. *ibid.*



Etude de l'évolution phonétique des langues

- Hypothèse Néogrammarienne : **Régularité des changements phonétiques**¹

Si, à un moment donné dans le temps, un phone d'une langue évolue en un autre phone dans un mot, alors toutes les occurrences de ce phone dans ce contexte évoluent de la même façon.

Ex : [ka] Latin Vulgaire > ... > [ʃa] Français

- *cattus* *[kat.tʊs] > *chat* [ʃa]
- *vacca* *[vak.ka] > *vache* [vaʃ]

- **Cognats**

Si plusieurs langues ont un ancêtre commun, des mots sont dits cognats si ils sont une évolution d'un même mot du dit-ancêtre, appelé leur proto-forme.

1. *ibid.*



Etude de l'évolution des langues

Méthodes d'identification de correspondances phonétiques :

- Comparaison automatique : alignement plus score de distance ou clustering²
- Méthodes inspirées de la traduction (MOSES³)
- Peu de réseaux de neurones... ('[The] structured perceptron model outperforms the encoder-decoder RNN.'⁴ 😞)

2. Johann-Mattis List, Simon J Greenhill et Russell D Gray, 'The potential of automatic word comparison for historical linguistics', *PloS one* 12:1 (2017).

3. Philipp Koehn *et al.*, *Moses : Open source toolkit for statistical machine translation*, dans : *Proceedings of the 45th annual meeting of the association for computational linguistics companion volume proceedings of the demo and poster sessions* (2007).

4. Peter Dekker, 'Reconstructing language ancestry by performing word prediction with neural networks', *Master. Amsterdam : University of Amsterdam* (2018).



Etude de l'évolution des langues

Méthodes d'identification de correspondances phonétiques :

- Comparaison automatique : alignement plus score de distance ou clustering²
- Méthodes inspirées de la traduction (MOSES³)
- Peu de réseaux de neurones... ('[The] structured perceptron model outperforms the encoder-decoder RNN.'⁴ 😊)

→ Peut-on utiliser des réseaux de neurones pour étudier des correspondances phonétiques ?

2. List *et al.* (cf. n° 2).

3. Koehn *et al.* (cf. n° 3).

4. Dekker (cf. n° 4).



Objectif

« Traduction » de cognats pour apprendre les changements phonétiques

Dans cet article

- Sur quel type de données peut-on apprendre des correspondances phonétiques ?
- Les méthodes neuronales peuvent-elles apprendre ces correspondances aussi bien que des modèles statistiques dans une situation idéale ?
- Les méthodes neuronales peuvent-elles apprendre aussi bien que des modèles statistiques en situations réelles ?


Précision : Score BLEU⁵

5. Matt Post, *A Call for Clarity in Reporting BLEU Scores*, dans : *Proceedings of the Third Conference on Machine Translation : Research Papers* (Brussels, Belgium: Association for Computational Linguistics, octobre 2018).



Comparaison des modèles

- MOSES : modèle statistique de référence⁶
- MEdEA : notre modèle neuronal (encodeur-décodeur⁷ avec attention⁸)



6. Koehn *et al.* (cf. n° 3).

7. Ilya Sutskever, Oriol Vinyals et Quoc V. Le, *Sequence to Sequence Learning with Neural Networks* (2014).

8. Minh-Thang Luong, Hieu Pham et Christopher D Manning, *Effective Approaches to Attention-based Neural Machine Translation*, dans : *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing* (2015).



Exploration des lexiques bilingues

Données :

Jeux de données	Cas d'utilisation	PL-CZ	PL-LT	PL-IT
Cognats	Test	370	47	57
Lexique bilingue	Entraînement	13,216	6,290	17,158

Table 1 – Jeux de données (phonétisés avec espeak⁹)

9. Jonathan Duddington, 'eSpeak : Text to speech',
<http://espeak.sourceforge.net/index.html> (2015).

Exploration des lexiques bilingues

Données :

Jeux de données	Cas d'utilisation	PL-CZ	PL-LT	PL-IT
Cognats	Test	370	47	57
Lexique bilingue	Entraînement	13,216	6,290	17,158

Table 1 – Jeux de données (phonétisés avec espeak⁹)

Résultats :

Langues	PL→CZ	PL→LT	PL→IT
Résultat sur les jeux de tests			
MEDeA	48.44 ± 1.13	19.22 ± 0.99	26.75 ± 1.05
MOSES	54.43 ± 0.41	20.55 ± 0.62	28.37 ± 0.62

Table 2 – Scores BLEU (moyenne sur 10 expériences)

9. *ibid.*



Et si on travaillait sur des données artificielles ?

Avantages des données artificielles : situation « idéale ».

10. András Cser, 'Aspects of the phonology and morphology of Classical Latin', Thèse de doctorat, Pázmány Péter Katolikus Egyetem (2016).



Et si on travaillait sur des données artificielles ?

Avantages des données artificielles : situation « idéale ».

Créer des données artificielles :

- Créer un proto-language
 - Inventaire de phones (Langues Romanes)
 - Phonotactique (Latin classique¹⁰)
- Générer des langues filles
 - Succession de changements phonétiques (apocope, épenthèse, palatalisation, lénition, prothèse de voyelle, diphtonguisation)

10. *ibid.*

Et si on travaillait sur des données artificielles ?

Avantages des données artificielles : situation « idéale ».

Créer des données artificielles :

- Créer un proto-language
 - Inventaire de phones (Langues Romanes)
 - Phonotactique (Latin classique¹⁰)
- Générer des langues filles
 - Succession de changements phonétiques (apocope, épenthèse, palatalisation, lénition, prothèse de voyelle, diphtonguisation)

Résultats : 20,000 triples de mots

- [ʒolpast] > [ʒolbes], [ʒolpes]
- [splutoi] > [isbledoi], [espletoi]

10. *ibid.*



Expérience

Tâche :

- Prédiction de « traductions » de phones, d'une langue mère (PL) à ses langues filles (LF), inversement, et des langues filles entre elles.

Questions :

- MEDeA peut-il apprendre des changements phonétiques ?
- Si oui, comment se compare-t-il au modèle statistique ?
- Quelle influence a la taille des données ? (500, 1000, 1500, 2000, 3000)
- Comment les modèles gèrent-ils l'ambiguïté ? (1, 2, 3 best - corpus BLEU)
[ʒolbes] < [ʒolpast] or [ʒolpest] or [ʒolpas] or [ʒolpes] or ...



Comparaison sur des données artificielles




Figure 1 – Comparaison selon différents sens de prédiction



Comparaison sur des données artificielles




Figure 2 – Influence de la taille des données et du nombre de réponses



Comparaison sur des données artificielles




Figure 2 – Influence de la taille des données et du nombre de réponses

- MEDeA peut apprendre !
- MOSES ++ → non-ambiguïté ou peu de données
- MEDeA ++ → ambiguïté, au dessus de 1000 mots

Quid de données réelles ?



Et sur données réelles ?

Tâche :

- Prédire des « traductions » de phones pour des langues Romanes - IT, ES, LA
 - LA-ES-IT : 605 triples de cognats (1/3 pour l'entraînement, 2/3 pour le test)
 - LA-IT : 5040 paires de cognats (pour l'entraînement)
 - LA-ES : 4208 paires de cognats (pour l'entraînement)
 - IT-ES : 1764 paires de cognats (pour l'entraînement)

Questions :

- Est ce que MEDeA peut apprendre sur des données réelles (donc bruitées)
- Si oui, comment se compare-t-il à MOSES ?



Comparaison sur données réelles

Exemple de l'italien-latin




Figure 3 – IT→LA




Figure 4 – LA→IT

Problème des cas en latin pendant l'extraction.



Une erreur est-elle toujours fausse ?

Une réponse est juste **par rapport au jeu de données**. Une prédiction « incorrecte » peut en fait appartenir à 3 situations :

- ❶ réponse historiquement valide
- ❷ réponse historiquement plausible
- ❸ réponse complètement incorrecte



Une erreur est-elle toujours fausse ?

Une réponse est juste **par rapport au jeu de données**. Une prédiction « incorrecte » peut en fait appartenir à 3 situations :

- ❶ réponse historiquement valide
- ❷ réponse historiquement plausible
- ❸ réponse complètement incorrecte

Exemple de [rustiko] 'rustique', venant de [rustikʊs] 'de la campagne'

- MEDeA : [rustikʊs] (masc. - bonne réponse), [rustikʊm] (neut. - cas 1), ou [rustikss] (aucun sens - cas 3)
- MOSES : [rʊkʊstɪ], [rʊɪkʊst] ou [ʊsrɪkwʊs] (toutes le cas 3)



Conclusion

Résultats :

- Sur des données idéales
 - Les réseaux de neurones sont meilleurs dans les situations d'ambiguïté (LF→PL)
 - Les modèles statistiques meilleurs sur de petits jeux de données
- Sur des données réelles (très bruitées)
 - La taille et la propreté des données sont importantes...

Et après ?

- Données artificielles plus complexes ?
- Création d'un autre score que BLEU ?
- Observation plus approfondies des différences entre modèles ?

○



References I

- Cser, András, 'Aspects of the phonology and morphology of Classical Latin', Thèse de doctorat, Pázmány Péter Katolikus Egyetem (2016).
- Dekker, Peter, 'Reconstructing language ancestry by performing word prediction with neural networks', *Master. Amsterdam : University of Amsterdam* (2018).
- Duddington, Jonathan, 'eSpeak : Text to speech', <http://espeak.sourceforge.net/index.html> (2015).
- Koehn, Philipp *et al.*, *Moses : Open source toolkit for statistical machine translation*, dans : *Proceedings of the 45th annual meeting of the association for computational linguistics companion volume proceedings of the demo and poster sessions* (2007), p. 177–180.

References II

- List, Johann-Mattis, Greenhill, Simon J et Gray, Russell D, 'The potential of automatic word comparison for historical linguistics', *PloS one* 12:1 (2017).
- Luong, Minh-Thang, Pham, Hieu et Manning, Christopher D, *Effective Approaches to Attention-based Neural Machine Translation*, dans : *Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing* (2015), p. 1412–1421.
- Osthoff, Hermann et Brugmann, Karl, *Morphologische Untersuchungen auf dem Gebiete der indogermanischen Sprachen*, volume 3 (S. Hirzel, 1880).

References III

- Post, Matt, *A Call for Clarity in Reporting BLEU Scores*, dans : *Proceedings of the Third Conference on Machine Translation : Research Papers* (Brussels, Belgium: Association for Computational Linguistics, octobre 2018), p. 186–191.
- Sutskever, Ilya, Vinyals, Oriol et Le, Quoc V., *Sequence to Sequence Learning with Neural Networks* (2014).